



JITE (Journal of Informatics and Telecommunication Engineering)

Available online <http://ojs.uma.ac.id/index.php/jite> DOI : 10.31289/jite.v5i1.5066

Received: 05 April 2021

Accepted: 02 July 2021

Published: 16 July 2021

Machine Learning with Decision Tree for Predict Invoice Payment, Case Study: Gramedia Jakarta

Firmansyah¹⁾, Agus Yulianto²⁾*

1) Program Studi Sistem Informasi, Fakultas Teknik & Informatika, Universitas Bina Sarana Informatika, Indonesia

2) Program Studi Sistem Informasi, STMIK Nusa Mandiri, Indonesia

*Corresponding Email: agus.aag@nusamandiri.ac.id

Abstrak

Arus keuangan yang lancar merupakan salah satu kunci agar perusahaan tetap bertahan dan memiliki keberlangsungan. Pembayaran atas faktur penjualan adalah salah satu masalah yang dapat mempengaruhi keuangan, jika pembayaran faktur terlambat maka perputaran kas menjadi lambat dan berdampak pada operasional perusahaan. Belum adanya alat yang dapat memprediksi pembayaran faktur di Gramedia menyulitkan bagian keuangan. Dari permasalahan itu, maka diterapkan machine learning untuk memprediksi pembayaran faktur oleh customer, apakah pembayarannya terlambat atau tidak terlambat. Proses dalam data mining menggunakan framework CRISP-DM (Cross Standard Industry for Data Mining). Fitur data yang digunakan sebagai parameter yaitu invoice amount, payment method, paid invoice, average days late dan ratio amount of overdue by amount of balance. Data faktur penjualan diprediksi menggunakan model decision tree algoritma C5.0 dengan hasil akurasi mencapai 71.84%. Algoritma C5.0 terbukti mampu memprediksi faktur yang pembayarannya terlambat (melewati jatuh tempo) dan pembayarannya tepat waktu (sebelum jatuh tempo).

Kata Kunci: machine learning, decision tree, C5.0 algorithm, crisp-dm, invoice overdue prediction, rapid miner.

Abstract

A smooth financial flow is one of the keys for the company to survive and have sustainability. Payment of sales invoices is one of the problems that can affect finances, if the invoice payment is late, the cash turnover will slow down and have an impact on company operations. The absence of a tool that can predict invoice payments at Gramedia makes it difficult for the finance department. From this problem, machine learning is applied to predict invoice payments by customers, whether the payment is late or not late. The process in data mining uses the CRISP-DM (Cross Standard Industry for Data Mining) framework. The data feature used as a parameter is invoice amount, payment method, paid invoice, average days late dan ratio amount of overdue by amount of balance. Sales invoice data is predicted using the decision tree model algorithm C5.0 with an accuracy of 71.84%. The C5.0 algorithm is proven to be able to predict invoices whose payments are late (past due) and payments are on time (before maturity).

Keywords: machine learning, decision tree, C5.0 algorithm, crisp-dm, invoice overdue prediction, rapid miner.

How to Cite: Firmansyah, & Yulianto, A. (2021). Machine Learning dengan Decision Tree untuk Prediksi Pembayaran Invoice, Case Study : Gramedia Jakarta. *JITE (Journal Of Informatics And Telecommunication Engineering)*. 5 (1): 167-175

I. PENDAHULUAN

Siklus penerimaan keuangan yang lancar adalah salah satu indikasi bahwa kondisi keuangan sebuah perusahaan baik. Salah satu yang perlu dikelola dalam keuangan perusahaan adalah piutang karena piutang merupakan bagian penting untuk mendapatkan keuntungan dan sebagai indikator pendapatan bisnis (Shah, 2019). Piutang tentunya terkait dengan invoice dimana perusahaan menerbitkan invoice

kemudian ditagihkan kepada customer. Piutang belum dapat dicatat sebagai pendapatan karena uang belum diterima oleh perusahaan, namun piutang penting sebagai modal kerja dan menjaga stabilitas keuangan perusahaan (Jindal et al., 2017). Perusahaan seringkali menghadapi masalah yang sama yaitu customer tidak membayar tagihan tepat waktu atau sebelum jatuh tempo, sehingga customer harus selalu diingatkan invoice sudah jatuh tempo atau lewat tempo (Cheong et al., 2018).

Piutang memiliki usia yang menggambarkan lamanya invoice dihitung sejak dari tgl faktur sampai dengan tanggal jatuh tempo. Semakin cepat customer membayar invoice maka akan semakin baik mempengaruhi keuangan karena kas perusahaan akan bertambah dan dapat memperbaiki siklus keuangannya. Saat ini perusahaan mengelola piutang menggunakan batas kredit (*credit limit*) dan usia piutang berdasarkan rata-rata penjualan untuk masing-masing pelanggan sehingga sering kali melewati batas kredit dan maksimum usia piutang akibat dari prediksi pembayaran faktur yang tidak tepat. Akurasi prediksi yang dilakukan saat ini mencapai 40.1%. Dari masalah tadi maka akan diterapkan algoritma C5.0 agar prediksi atas pembayaran faktur lebih akurat.

Dengan melakukan prediksi atas invoice penjualan, maka algoritma c5.0 dapat memprediksi apakah kemungkinan pembayarannya sebelum jatuh tempo atau setelah jatuh tempo. Dari hasil prediksi, perusahaan dapat menentukan kebijakan seperti limit kredit piutang terhadap customer atau lama tempo fakturnya.

Banyak penelitian yang sudah dilakukan terkait prediksi jatuh tempo invoice seperti prediksi piutang karyawan (Aguilar et al., 2018), prediksi pembayaran invoice dengan menggunakan 5 algoritma ML yaitu Naive Bayes, LR, k-Nearest Neighbor, Random Forest dan Decision Trees (Appel et al., 2019), Bahrami menggunakan algoritma LR, SVM dan OneR untuk memprediksi pembayaran invoice (Bahrami et al., 2020), prediksi kelancaran pembayaran (Irawan & Samopa, 2019), segmentasi dan klasifikasi kebiasaan pembayaran customer (Moedjiono et al., 2016), prediksi pembayaran piutang customer dengan AdaBoost (Shah, 2019)

II. STUDI PUSTAKA

A. Penelitian Terkait

Penelitian untuk memprediksi piutang menggunakan multiclass data mining (Irawan & Samopa, 2018) dan prediksi menggunakan AdaBoost (Shah, 2016) untuk memprediksi apakah piutang akan melewati jatuh tempo. Prediksi piutang berdasarkan customer level oleh (Cheong & Wen Shi, 2018) bertujuan untuk memprediksi piutang customer. Penelitian untuk memprediksi pembayaran atas faktur menggunakan machine learning (Appel,dkk, 2020) dan analisa kebiasaan customer (Bahrami, Bozkaya, Balcisoy, 2020), segmentasi dan klasifikasi kebiasaan customer menggunakan K-means dan C4.5 (Moedjiono, Fransisca, KUSDARYANTO, 2016) dengan tujuan untuk memprediksi pembayaran faktur. Prediksi piutang juga menggunakan Artificial Intelligence (AI) menggunakan random forest (Nanda, 2018) dan klasifikasi menggunakan naive bayes untuk penilaian resiko (Krichene, 2017)

B. *Managemen Piutang (Account Receivable Management)*

Piutang perlu dikelola baik untuk perusahaan kecil, menengah maupun besar. Penerimaan piutang yang dikelola berpengaruh pada perencanaan yang lebih baik dan management yang efisien (Duru et al., 2014). Fakta menunjukkan bahwa penerimaan pembayaran yang lebih cepat maka akan menaikkan likuiditas perusahaan (Menkinoski et al., 2016).

Secara umum, pembagian usia piutang rentangnya 30 hari, 45 hari, 60 hari, 120 hari bahkan lebih dari 120 hari. Tentunya keuangan perusahaan akan lebih baik jika pembayaran diterima sebelum jatuh tempo, karena pembayaran piutang yang melebihi jatuh tempo akan mempengaruhi keuangan perusahaan. Oleh karena hal itu, banyak perusahaan menerapkan pengelolaan piutang seperti menetapkan credit limit, pembatasan jatuh tempo, pengelolaan penagihan hingga penalti.

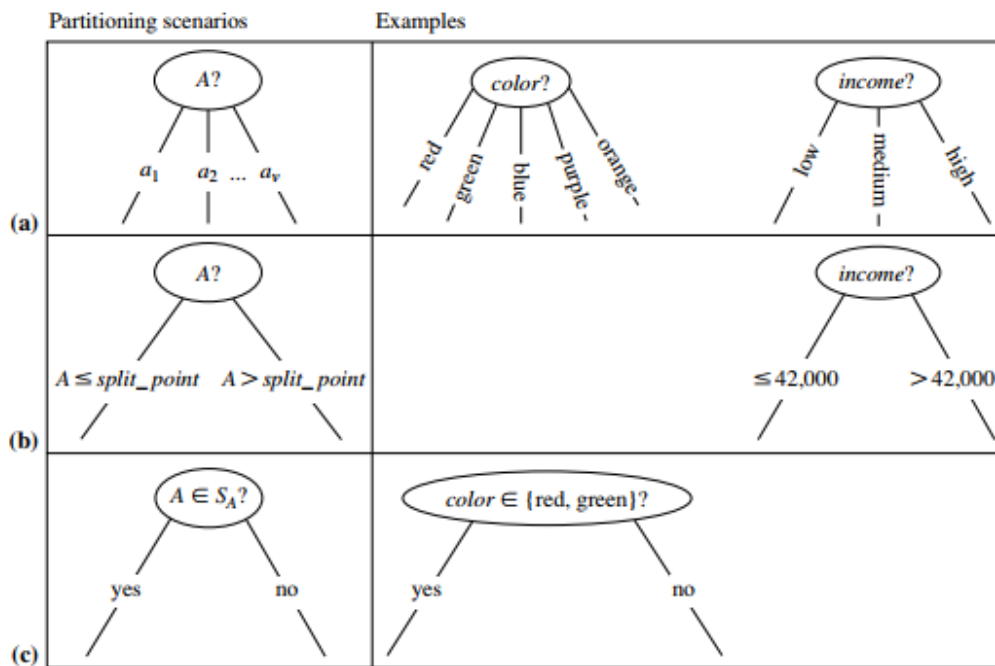
C. *Decision Tree*

Decision Tree merupakan sekian dari banyak metode di dalam data mining, dimana data mining adalah proses mengekstrak data dengan menggunakan metode dan algoritma tertentu untuk menghasilkan informasi yang lebih berguna sehingga dapat menjadi dasar dalam pengambilan keputusan (Firmansyah & Yulianto, 2021). Diperkenalkan pertama kali oleh J. Ross Quinlan di awal tahun 1980

dengan nama ID3. Decision tree adalah flowchart yang memiliki struktur pohon dimana masing-masing node nya memiliki atribut, setiap cabang menggambarkan keluaran dari pengujian dan setiap daun memiliki label (Han et al., 2012). Pada tahun-tahun berikutnya barulah Quinlan memperkenalkan C4.5 sebagai algoritma supervised learning yang lebih baru sebagai penyempurnaan dari ID3.

Algoritma C5.0 merupakan penyempurnaan dari C4.5 dimana C5.0 lebih cepat dan efisien dalam penggunaan memori sehingga cocok untuk diterapkan ke dalam data yang besar (Kumar & Kiruthika, 2013), namun C5.0 juga memiliki kekurangan yaitu kurang baik dalam memproses data training yang kecil (Jadhav & Channe, 2016). Proses di dala, algoritma C5.0 sama dengan algoritma C4.5, perbedaannya untuk algoritma C5.0 menggunakan persamaan gain ratio untuk menentukan node di parent berikutnya.

Decision Tree (DT) dapat memproses 3 skenario berdasarkan data. Skenario partisi yaitu data yang bernilai diskrit, numerik dan kategorikal



Gambar 1 Partitioning Scenarios

1. Entropy

Entropy adalah nilai informasi yang menyatakan ukuran ketidakpastian dari attribute dari kumpulan obyek data dalam satuan bit. Persamaan untuk menghitung nilai entropy yaitu :

$$\text{Entropy}(S) = - \sum_{i=1}^n P_i * \log_2 P_i \quad (1)$$

Dimana :

S = himpunan kasus

n = jumlah partisi |S|

Pi = proporsi dari |Si| terhadap |S|

2. Information Gain

Information Gain merupakan ukuran efektifitas suatu atribut dalam mengklasifikasikan data. Digunakan untuk menentukan atribut dimana atribut yang memiliki nilai terbesar yang akan dipilih. Persamaannya yaitu :

$$\text{InformationGain}(S,A) = \text{Entropy}(S) - \sum_{i=1}^n * \text{Entropy}(S_i) \quad (2)$$

Dimana :

S = himpunan kasus

A = atribut

n = jumlah partisi dari atribut A

|S_i| = jumlah kasus pada partisi ke-i

|S| = jumlah kasus dalam S

3. Gain Ratio

Gain ratio berfungsi untuk memodifikasi nilai dari information gain untuk mengurangi nilai bias terhadap atribut yang multi-value. Persamaannya yaitu :

$$GR(S,A) = \frac{Gain(S,A)}{Intl(S,A)} \quad (3)$$

III. METODE PENELITIAN

A. CRISP-DM (Cross-Industry Standard Process for Data Mining)

Metode berisi informasi

Metode dalam implementasi data mining menggunakan framework CRISP-DM (Cross-Industry Standard Process for Data Mining) yang merupakan standard metode penerapan data mining untuk industri (Larose, 2006), fasenya yaitu :

1. Business Understanding Phase
2. Data Understanding Phase
3. Data Preparation Phase
4. Modelling Phase
5. Evaluation Phase
6. Deployment Phase



Gambar 2 CRISP-DM Process

B. Decision Tree : Algoritma C5.0

Langkah dalam membentuk decision tree yaitu :

1. Hitung setiap kemunculan kejadian pada setiap prediktor dari atribut yang digunakan terhadap prediktor dari target
2. Hitung entropy total dan entropy untuk setiap prediktor atribut
3. Hitung information gain untuk setiap atribut. Information gain dengan nilai tertinggi pada iterasi pertama akan menjadi root tree atau akar.
4. Ulangi perhitungan information gain sampai semua atribut masuk ke dalam kelas yang sama. Atribut yang sudah dipilih tidak dimasukkan lagi dalam perhitungan nilai information gain di iterasi berikutnya.

IV. HASIL DAN PEMBAHASAN

Gramedia merupakan toko retail buku dan ATK dimana datanya sangat besar. Dibutuhkan algoritma yang dapat memproses untuk memprediksi jatuh tempo faktur berdasarkan data historis. Tujuannya agar organisasi dapat memprediksi faktur berikutnya apakah pembayarannya sebelum jatuh tempo atau setelah jatuh tempo.

A. Data Training dan Data Testing

Data transaksi diambil dari data penjualan mulai periode Januari 2021 sampai dengan Februari 2021 sejumlah 1.748 baris data. Dari data transaksi, proses berikutnya dilakukan pembersihan data seperti menghilangkan duplikasi dan missing values. Data yang sudah dilakukan pembersihan bisa diambil menjadi data training dan data testing. Terdapat 6 variabel yang dijadikan acuan, yaitu nilai invoice (invoice amount), metode pembayaran (payment method), status pembayaran faktur (paid invoice), rata-rata keterlambatan pembayaran faktur (average days late) dan rasio nilai faktur yang melewati jatuh tempo dengan nilai piutang (ratio amount of overdue by amount of balance). Setiap variabel kemudian diklasifikasi menjadi seperti di bawah ini :

Tabel 1. Klasifikasi variabel

Variable name	Class
Invoice Amount	0 - 1.000.000 1.000.001 - 2.000.000 2.000.001 - 3.000.000 3.000.001 - 4.000.000 4.000.001 - 5.000.000 > 5.000.001
Payment method	Transfer Cash
Paid invoice	Paid UnPaid
Average days late	0-30 days 31-60 days
Ratio amount of overdue by amount of balance	0 - 0,2 0,3 - 0,4 0,5 - 0,6 0,7 - 0,8 0,9 - 1
Class	Payment late / payment not late

Dari data transaksi yang sudah diklasifikasikan, data training diambil secara acak sebesar 70% dan data testing sebesar 30%.

B. Algoritma Decision Tree C5.0

Untuk membentuk root, terlebih dahulu dibuat tabel kemunculan kejadian seperti di bawah ini :

Tabel 2. Tabel Jumlah Kemunculan Kejadian

Node			Total	Payment late	Payment not late
	Total		1747	991	756
	Invoice amount	0 - 1.000.000	1732	984	748
		1.000.001 - 2.000.000	9	6	3
		2.000.001 - 3.000.000	2	1	1
		3.000.001 - 4.000.000	2	0	2
		4.000.001 - 5.000.000	1	0	1
		> 5.000.001	1	0	1
	Payment method	Transfer	1114	621	493
		Cash	633	370	263
	Paid invoice	Paid	1113	637	476
		Not yet paid	634	354	280
	Average days late	0-30 days	1523	867	656
		31-60 days	224	124	100
	Ratio amount of overdue by amount of balance	0 - 0,2	187	117	70
		0,3 - 0,4	295	162	133
		0,5 - 0,6	680	389	291
		0,7 - 0,8	354	187	167
		0,9 - 1	231	139	95

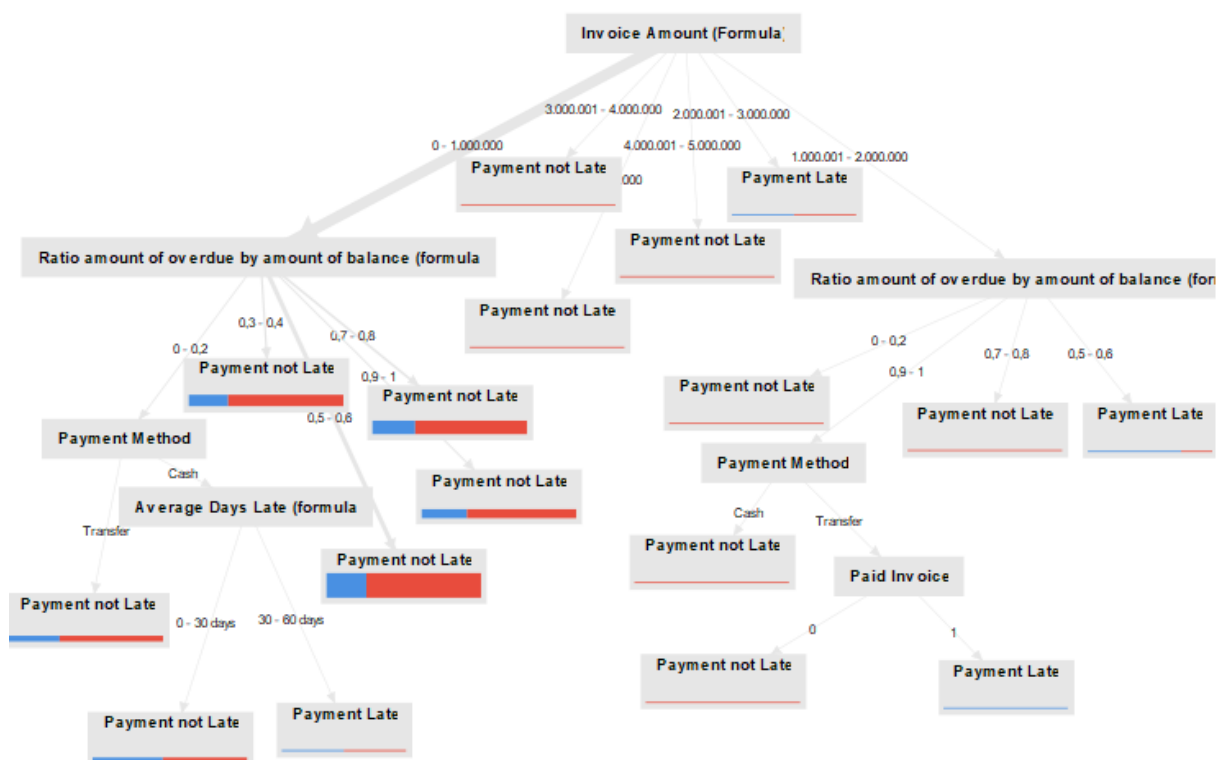
Kemudian dilakukan perhitungan untuk mendapatkan entropy dan information gain dengan menggunakan persamaan 1, hasilnya dibuat dalam tabel di bawah ini :

Tabel 3. Perhitungan Entropy, Information Gain dan Gain Ratio

Node			Entropy	Information gain	Gain ratio
	Total		0,9868		
	Invoice amount	0 - 1.000.000	0,9865	0,003	0,0014
		1.000.001 - 2.000.000	0,9182		
		2.000.001 - 3.000.000	1		
		3.000.001 - 4.000.000	0		
		4.000.001 - 5.000.000	0		
		> 5.000.001	0		
	Payment method	Transfer	0,9903	0,0007	0,00036
		Cash	0,9792		
	Paid invoice	Paid	0,9847	0,0002	0,00010
		Not yet paid	0,9901		
	Average days late	0-30 days	0,986	0,0099	0,0049
		31-60 days	0,9916		
	Ratio amount of overdue by	0 - 0,2	0,9538	0,0039	0,00079

	amount of balance				
		0,3 - 0,4	0,9929		
		0,5 - 0,6	0,9849		
		0,7 - 0,8	0,9976		
		0,9 - 1	0,968		

Data diproses menggunakan Decision Tree Algoritma C5.0, perangkat lunak yang digunakan adalah Rapid Miner 9.1. Decision tree yang dihasilkan seperti di bawah ini :



Gambar 3 Decision Tree Algoritma C5.0

Hasil rule yang sudah diproses dengan Decision Tree seperti di bawah ini :

Tree

```

Invoice Amount (Formula) = 0 - 1.000.000
|   Ratio amount of overdue by amount of balance (formula) = 0 - 0,2
|   |   Payment Method = Cash
|   |   |   Average Days Late (formula) = 0 - 30 days: Payment not Late {Payment
Late=19, Payment not Late=24}
|   |   |   Average Days Late (formula) = 30 - 60 days: Payment Late {Payment
Late=3, Payment not Late=3}
|   |   |   Payment Method = Transfer: Payment not Late {Payment Late=39, Payment not
Late=80}
|   |   Ratio amount of overdue by amount of balance (formula) = 0,3 - 0,4: Payment not
Late {Payment Late=66, Payment not Late=197}
|   |   Ratio amount of overdue by amount of balance (formula) = 0,5 - 0,6: Payment not
Late {Payment Late=156, Payment not Late=449}
|   |   Ratio amount of overdue by amount of balance (formula) = 0,7 - 0,8: Payment not
Late {Payment Late=89, Payment not Late=229}
|   |   Ratio amount of overdue by amount of balance (formula) = 0,9 - 1
|   |   |   Payment Method = Cash: Payment not Late {Payment Late=16, Payment not
Late=53}
|   |   |   Payment Method = Transfer
|   |   |   |   Average Days Late (formula) = 0 - 30 days: Payment not Late {Payment
Late=34, Payment not Late=78}
|   |   |   |   Average Days Late (formula) = 30 - 60 days

```

```

| | | | Paid Invoice = 0: Payment not Late {Payment Late=5, Payment not
Late=8}
| | | | Paid Invoice = 1: Payment Late {Payment Late=5, Payment not Late=5}
Invoice Amount (Formula) = 1.000.001 - 2.000.000
| Ratio amount of overdue by amount of balance (formula) = 0 - 0,2: Payment not
Late {Payment Late=0, Payment not Late=1}
| Ratio amount of overdue by amount of balance (formula) = 0,5 - 0,6: Payment Late
{Payment Late=3, Payment not Late=1}
| Ratio amount of overdue by amount of balance (formula) = 0,7 - 0,8: Payment not
Late {Payment Late=0, Payment not Late=1}
| Ratio amount of overdue by amount of balance (formula) = 0,9 - 1
| | Payment Method = Cash: Payment not Late {Payment Late=0, Payment not Late=1}
| | Payment Method = Transfer
| | | Paid Invoice = 0: Payment not Late {Payment Late=0, Payment not Late=1}
| | | Paid Invoice = 1: Payment Late {Payment Late=1, Payment not Late=0}
Invoice Amount (Formula) = 2.000.001 - 3.000.000: Payment Late {Payment Late=1,
Payment not Late=1}
Invoice Amount (Formula) = 3.000.001 - 4.000.000: Payment not Late {Payment Late=0,
Payment not Late=1}
Invoice Amount (Formula) = 4.000.001 - 5.000.000: Payment not Late {Payment Late=0,
Payment not Late=2}
Invoice Amount (Formula) = >5.000.000: Payment not Late {Payment Late=0, Payment not
Late=1}

```

Akurasi data diukur dengan menggunakan confusion matrix dan rapid miner, hasil akurasi mencapai 71.84% dan classification error sebesar 28.16%.

accuracy: 71.84%

	true Payment Late	true Payment not Late	class precision
pred. Payment Late	0	1	0.00%
pred. Payment not Late	48	125	72.25%
class recall	0.00%	99.21%	

Gambar 4 Accuracy

classification_error: 28.16%

	true Payment Late	true Payment not Late	class precision
pred. Payment Late	0	1	0.00%
pred. Payment not Late	48	125	72.25%
class recall	0.00%	99.21%	

Gambar 5 Classification Error

V. SIMPULAN

Dari bahasan di atas dapat disimpulkan bahwa algoritma C5.0 dapat memprediksi apakah pembayaran faktur akan tepat waktu atau melewati jatuh tempo berdasarkan data historis dengan tingkat akurasi mencapai 71.84% dan classification error sebesar 28.16% dimana pada proses prediksi yang dilakukan sebelumnya hanya mencapai akurasi 40.1 %. Rule yang terbentuk dari proses modelling algoritma C5.0 dapat diterapkan sebagai rule induction pada machine learning. Dengan machine learning, maka akan mempermudah prediksi dan membantu manusia dalam melakukan analisa sehingga perusahaan dapat melakukan langkah-langkah yang sesuai dengan prediksi.

DAFTAR PUSTAKA

- Aguilar, J. A. H., Montoya, E., Zavala, A. O. J. C., & Mayo, A. R. P. (2018). The Use of Data Mining Applied In the Accounts Receivable from the Employees of a Government Institution in México. *Journal of Computer Science and Information Technology*, 6(1), 34–43. <https://doi.org/10.15640/jcsit.v6n1a4>
- Appel, A. P., Oliveira, V., Lima, B., Malfatti, G. L., de Santana, V. F., & de Paula, R. (2019). Optimize Cash Collection: Use Machine Learning to Predicting Invoice Payment. *ArXiv*.
- Bahrami, M., Bozkaya, B., & Balcisoy, S. (2020). Using Behavioral Analytics to Predict Customer Invoice Payment. *Big Data*, 8(1), 25–37. <https://doi.org/10.1089/big.2018.0116>
- Cheong, M. L. F., Cheong, M. L. F., & Shi, W. (2018). Customer Level Predictive Modeling for Accounts Receivable to Reduce Intervention Actions Customer Level Predictive Modeling for Accounts Receivable to Reduce Intervention Actions. *Proceedings of the 14th International Conference on Data Science (ICDATA 2018), Las Vegas, Nevada, July 30 - August 2., IcdData*, Research Collection School Of Information Systems.
- Duru, A. N., Ekwe, M. C., & Okpe, I. I. (2014). *Accounts Receivable Management and Corporate Performance of Companies in The Food & Beverage Industry : Evidence from Nigeria*. 2(10), 1056–1063.
- Firmansyah, & Yulianto, A. (2021). Market Basket Analysis for Books Sales Promotion using FP Growth Algorithm, Case Study : Gramedia Matraman Jakarta. *Journal of Informatics And Telecommunication Engineering*, 4(January), 383–392.
- Han, J., Kamber, M., & Pei, J. (2012). *Data Mining Concepts and Techniques* (3rd ed.). Elsevier Inc.
- Irawan, F., & Samopa, F. (2019). Accounts Receivable Seamless Prediction for Companies by Using Multiclass Data Mining Model. *IPTEK Journal of Proceedings Series*, 0(1), 1. <https://doi.org/10.12962/j23546026.y2019i1.5096>
- Jadhav, S. D., & Channe, H. P. (2016). Comparative Study of K-NN, Naive Bayes and Decision Tree Classification Techniques. *International Journal of Science and Research (IJSR)*, 5(1), 1842–1845. <https://doi.org/10.21275/v5i1.nov153131>
- Jindal, D., Jain, S., & Vartika. (2017). Effect of Receivables Management on Profitability : A Study of Commercial Vehicle Industry in India. *International Journal of Applied Sciences and Management*, 2(2), 246–255.
- Krichene, A. (2017). Using a naive Bayesian classifier methodology for loan risk assessment: Evidence from a Tunisian commercial bank. *Journal of Economics, Finance and Administrative Science*, 22(42), 3–24. <https://doi.org/10.1108/JEFAS-02-2017-0039>
- Kumar, S. V. K., & Kiruthika, P. (2013). An Overview of Classification Algorithm in Data Mining. *International Journal of P2P Network Trends and Technology (IJPTT)*, 4(8), 369–374. <https://doi.org/10.17148/IJARCCCE.2015.41259>
- Larose, D. T. (2006). *Data Mining Methods and Models*. Johns Wiley & Sons.
- Menkinoski, G., Nikolovski, P., Karadjova, V., & Dičevska, S. (2016). Accounts Receivable Management - Important Task under Conditions of Globalization. *IJSBAR*, 27, 88–94. <https://translate.google.com/translate?hl=es&sl=en&u=http://gssrr.org/index.php%3Fjournal%3DJournalOfBasicAndApplied%26page%3Darticle%26op%3Ddownload%26path%255B%255D%3D5281%26path%255B%255D%3D2861&prev=search%0A>
- Moedjiono, S., Fransisca, F., & Kusdaryono, A. (2016). Segmentation and Classification Customer Payment Behavior at Multimedia Service Provider Company with K-Means and C4.5 Algorithm. *International Journal of Computer Networks and Communications Security*, 4(9), 265–275.
- Shah, H. S. (2019). Customer Payment Prediction in Account Receivable. *International Journal of Science and Research (IJSR)*, 8(1), 642–644. <https://www.ijsr.net/archive/v8i1/ART20194177.pdf>